

Corrélation

Contexte: On souhaite étudier le lien statistique entre 2 variables numériques.

Ex: \rightarrow Lieu entre T° à Paris et P° à Paris

\rightarrow Lieu entre Cons/km et Capacité du Réservoir

Apporté historique

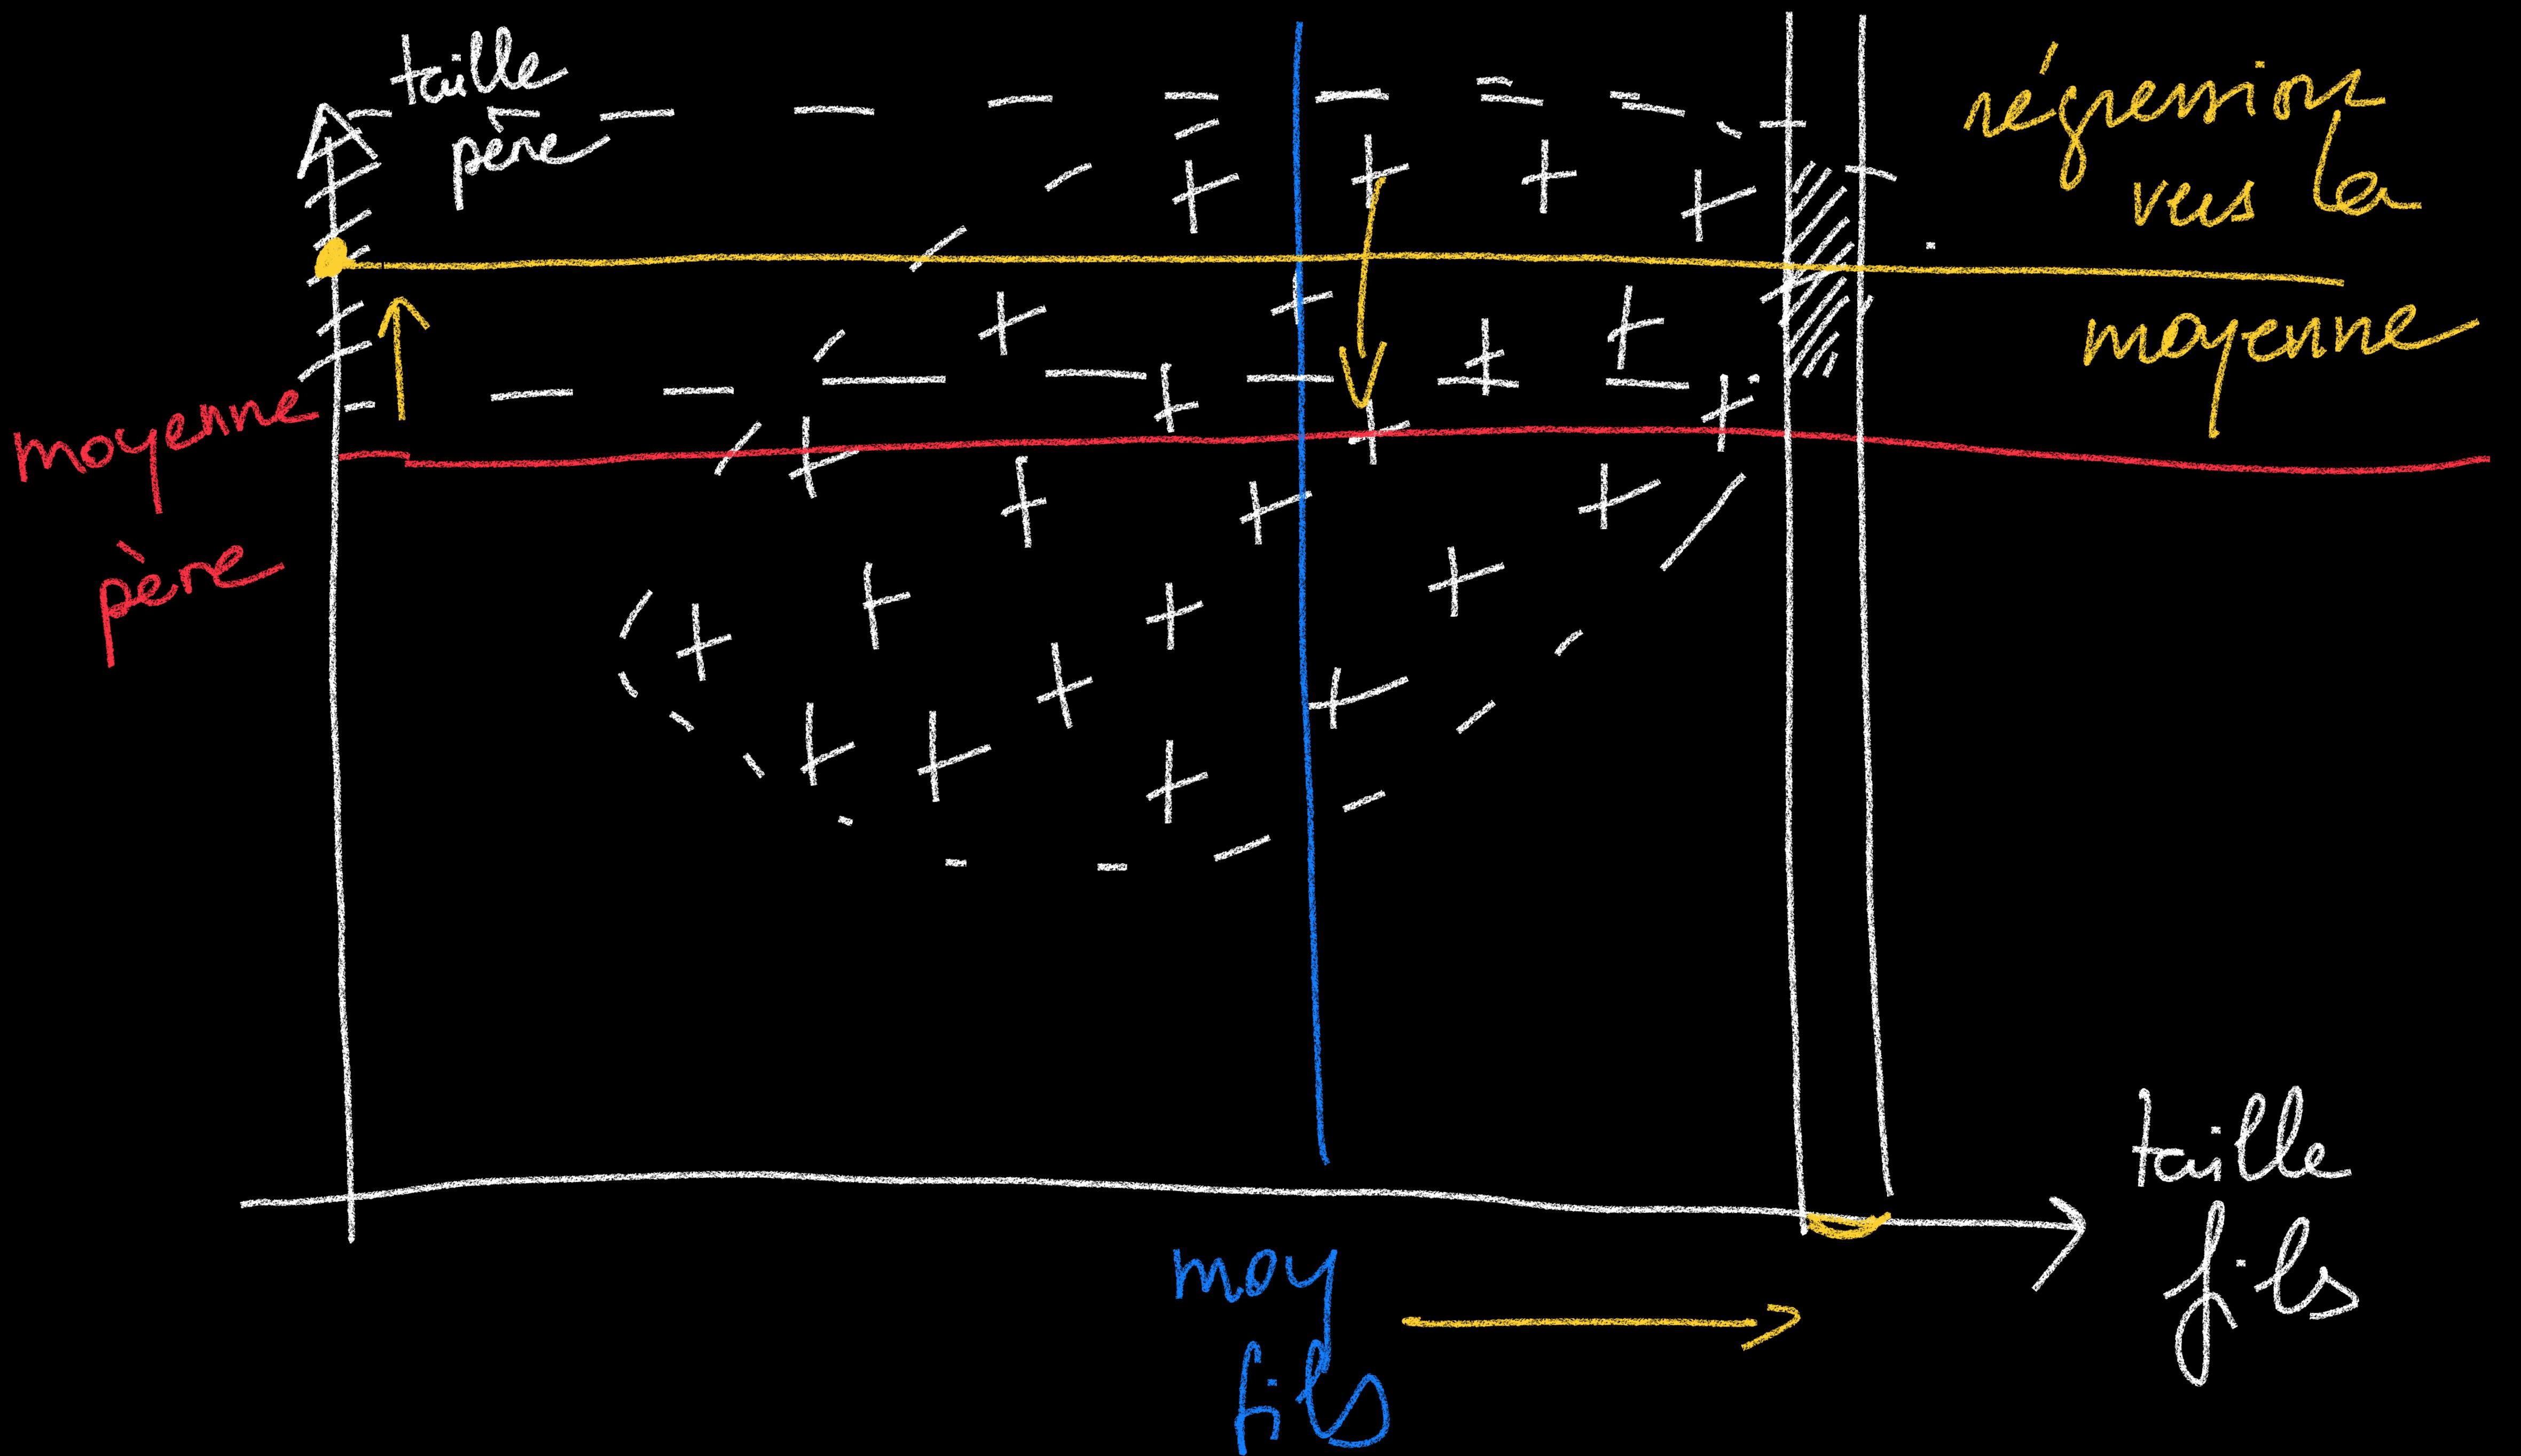
Régression vers la moyenne

Les parents qui sont très grands par rapport à la moyenne

1) L'enfant sera en général + grand que la moyenne

2) L'écart de taille par rapport à la moyenne sera moins élevé en général que celui de ses parents.

Un enfant très grand / moyenne a une
en général un père dont l'âge
par rapport à la moyenne est
moins élevé.



$X = \text{taille père}$

$Y = \text{taille fils}$

x_1 167

y_1 153

x_2 .

y_2 .

x_n .

y_n .

\bar{x}

\bar{y}

$$r = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sigma_x \cdot \sigma_y}$$

Covariance
 (X et Y)

permet
 de
 normaliser

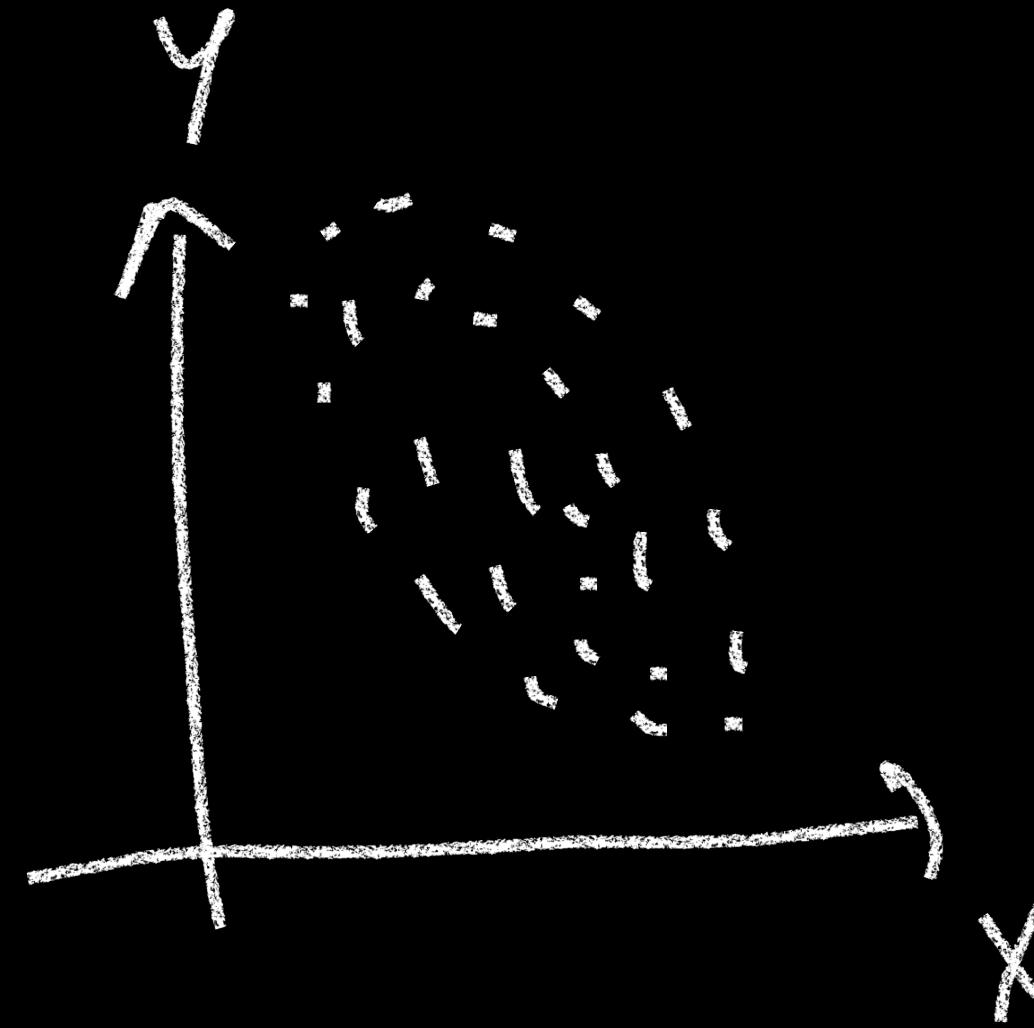
11/20

15/20

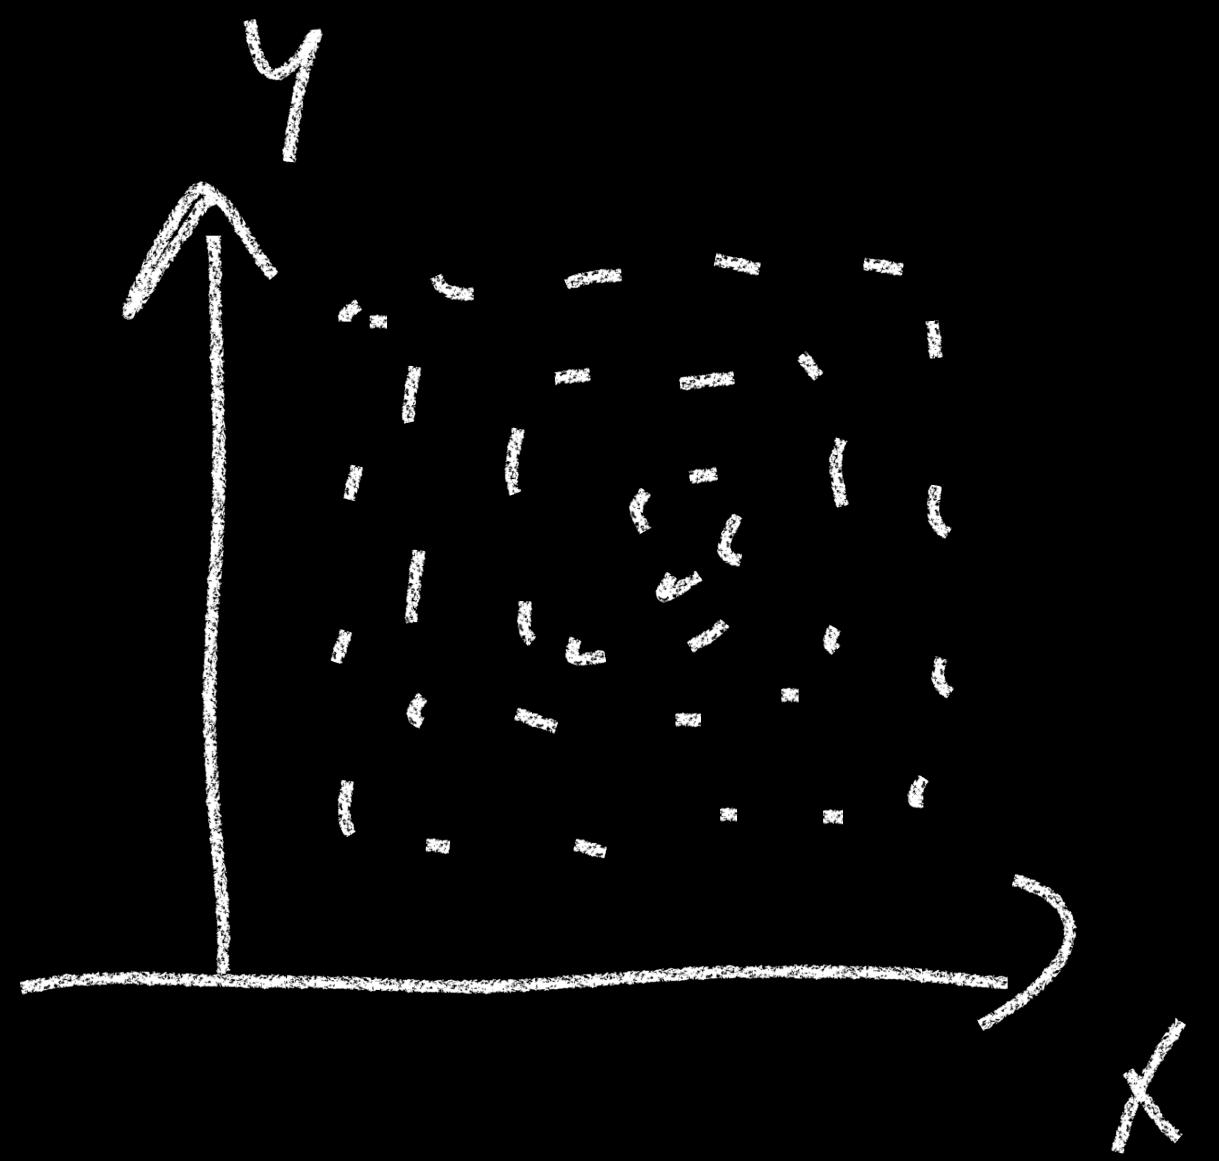
17/20

Covariance \Rightarrow Co - Variance

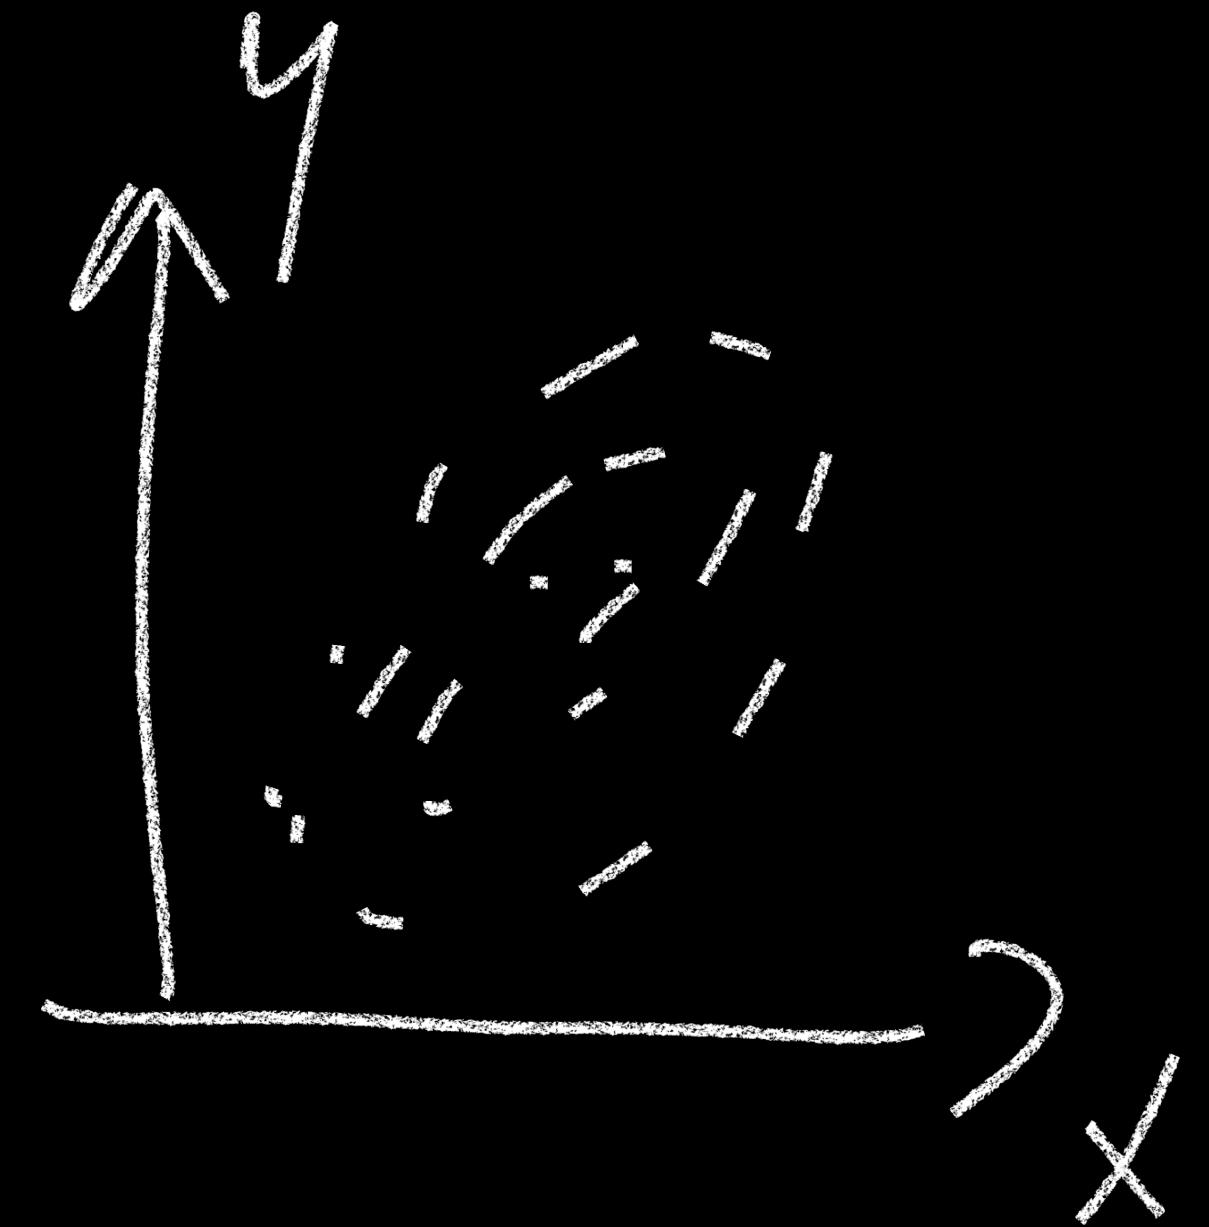
- \Rightarrow Variance ensemble
- Si lorsque $X \uparrow$, Y ne varie pas, $\text{cov} \geq 0$
 - Si lorsque $X \uparrow$, en règle générale
 $Y \uparrow$, alors cov est élevé et > 0
 - Si lorsque $X \uparrow$, $Y \downarrow$, $|\text{cov}|$ est élevé et $\text{cov} < 0$



$$n \geq -1$$



$$n \geq 0$$



$$n \geq +1$$

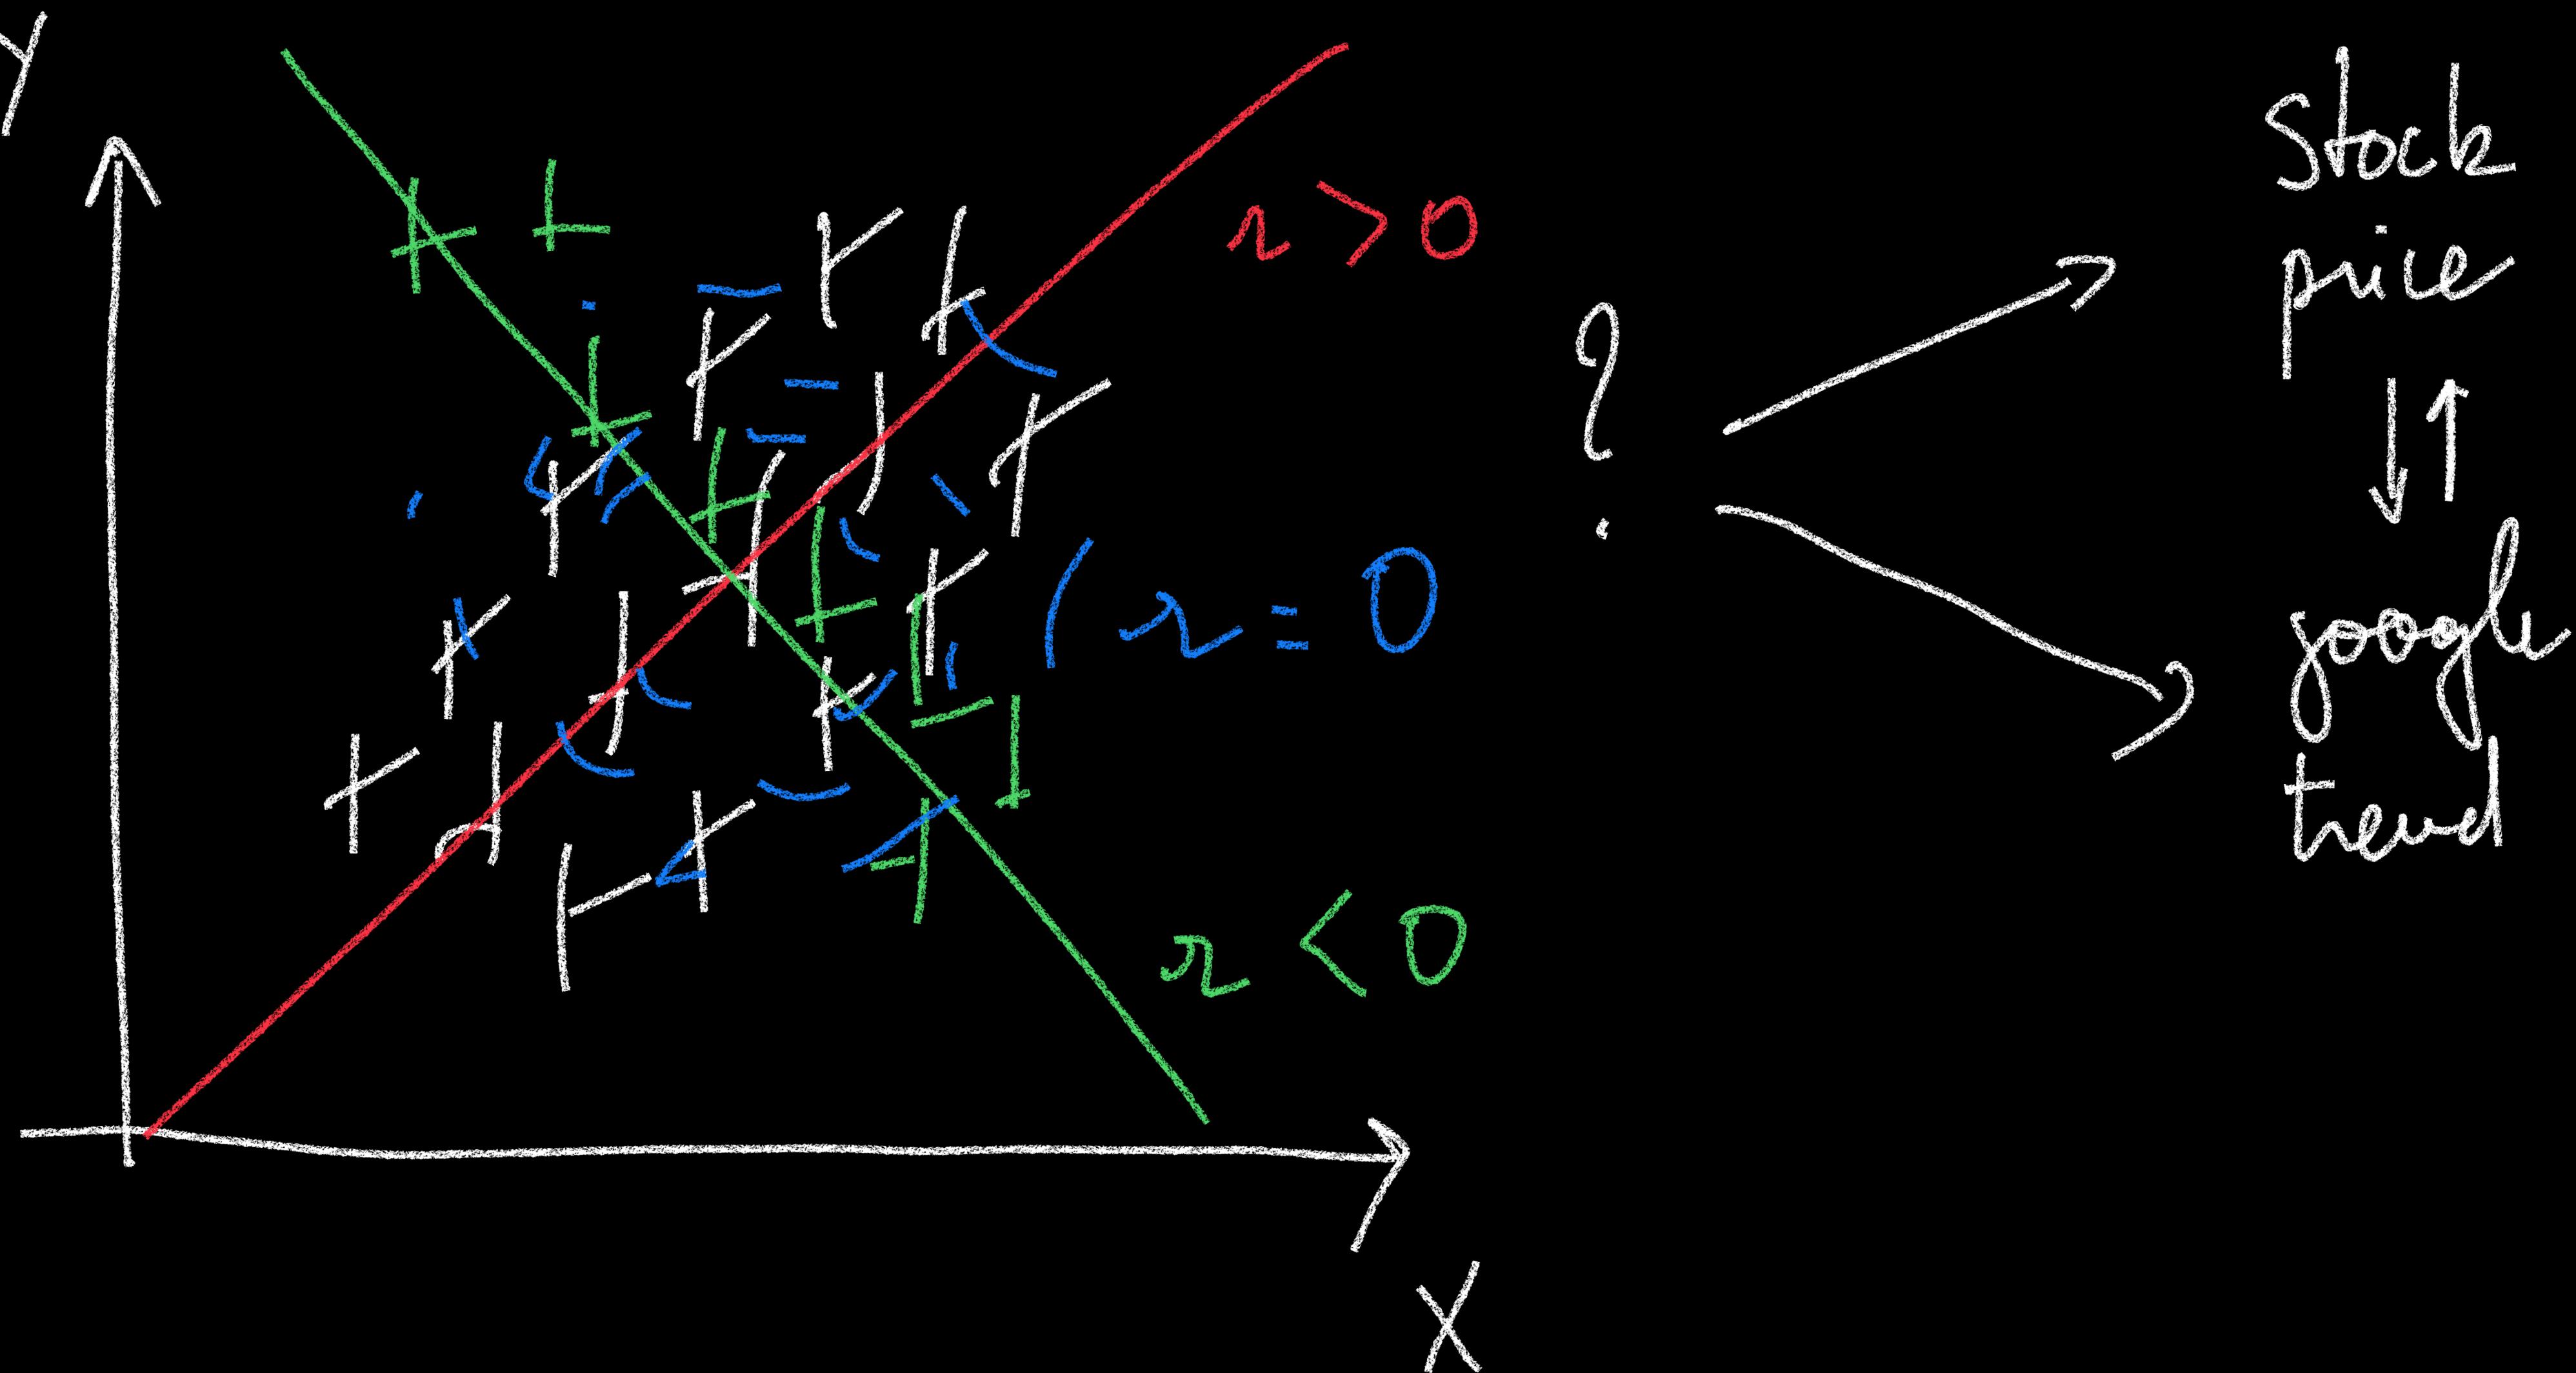


Le score de corrélation r de Pearson
est utilisé pour quantifier le
lien statistique entre 2 variables
numériques

Performance = Talent + Chance

Perf_{1A} ↑ = Talent ↑ + Chance ↑

Perf_{2A} ↓ = Talent ↑ + Chance ↓



Stock
price
 $\downarrow 1$
google
trend

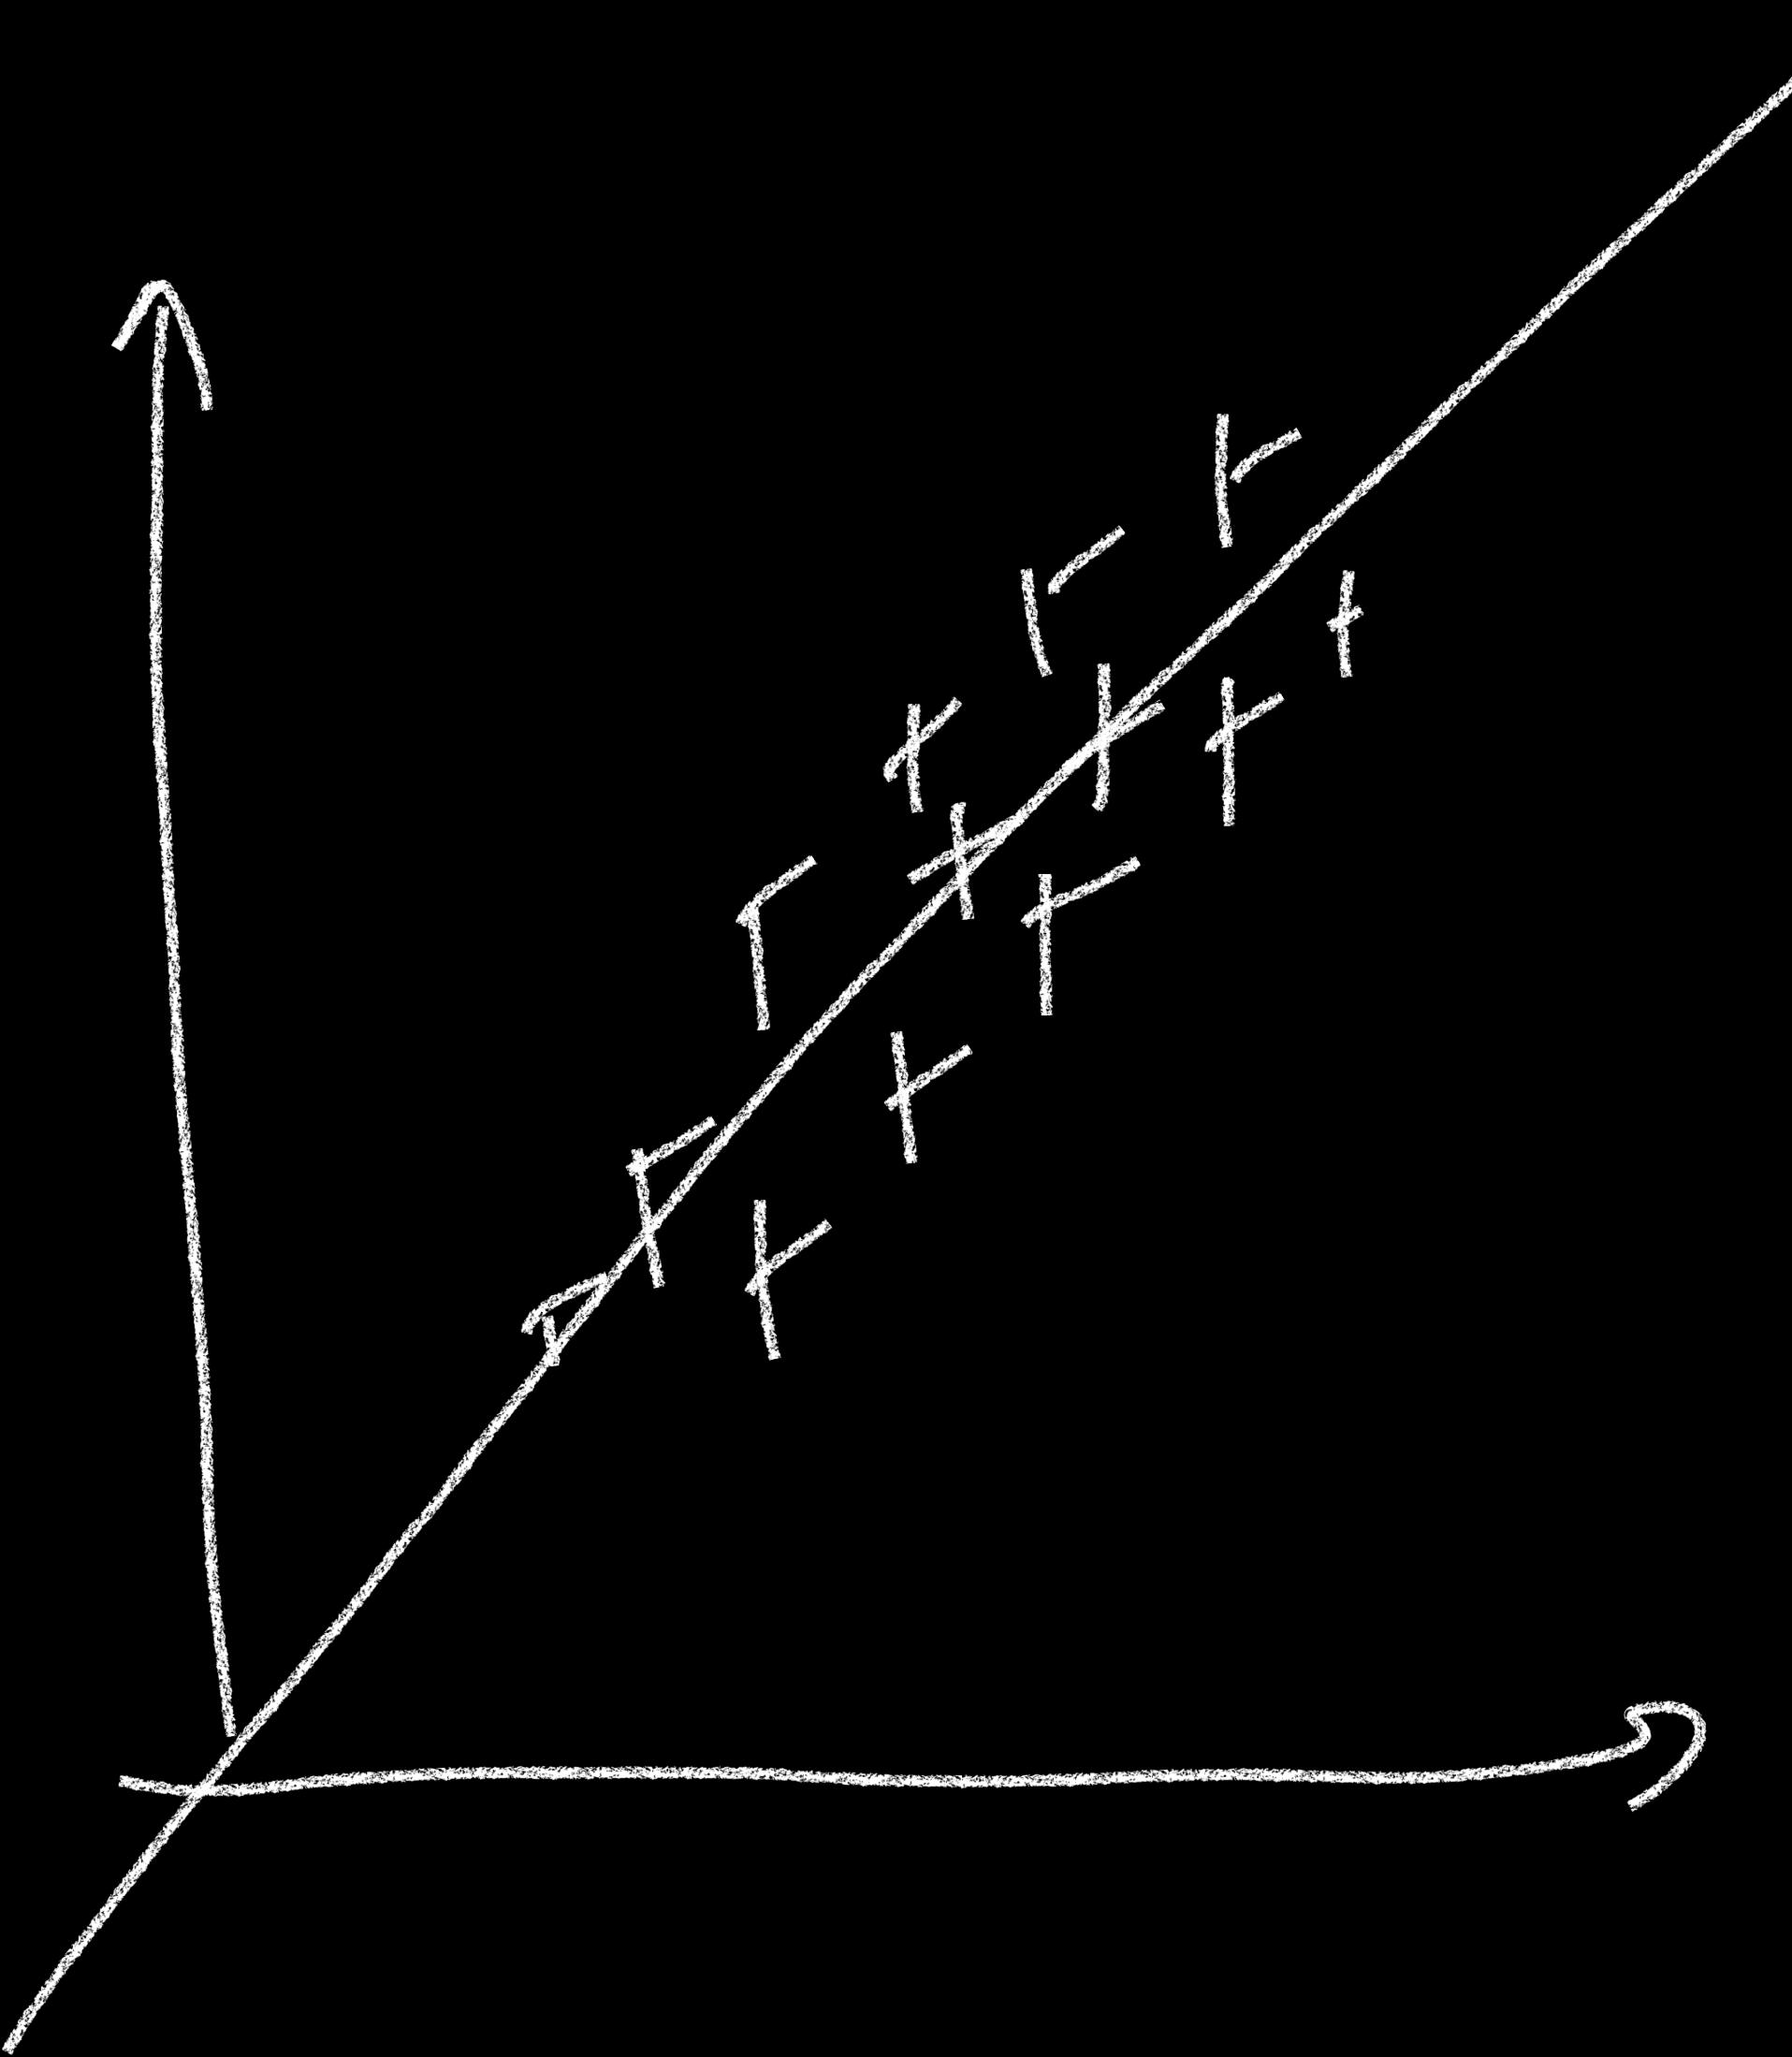
$$r = 0,34$$

X, Y

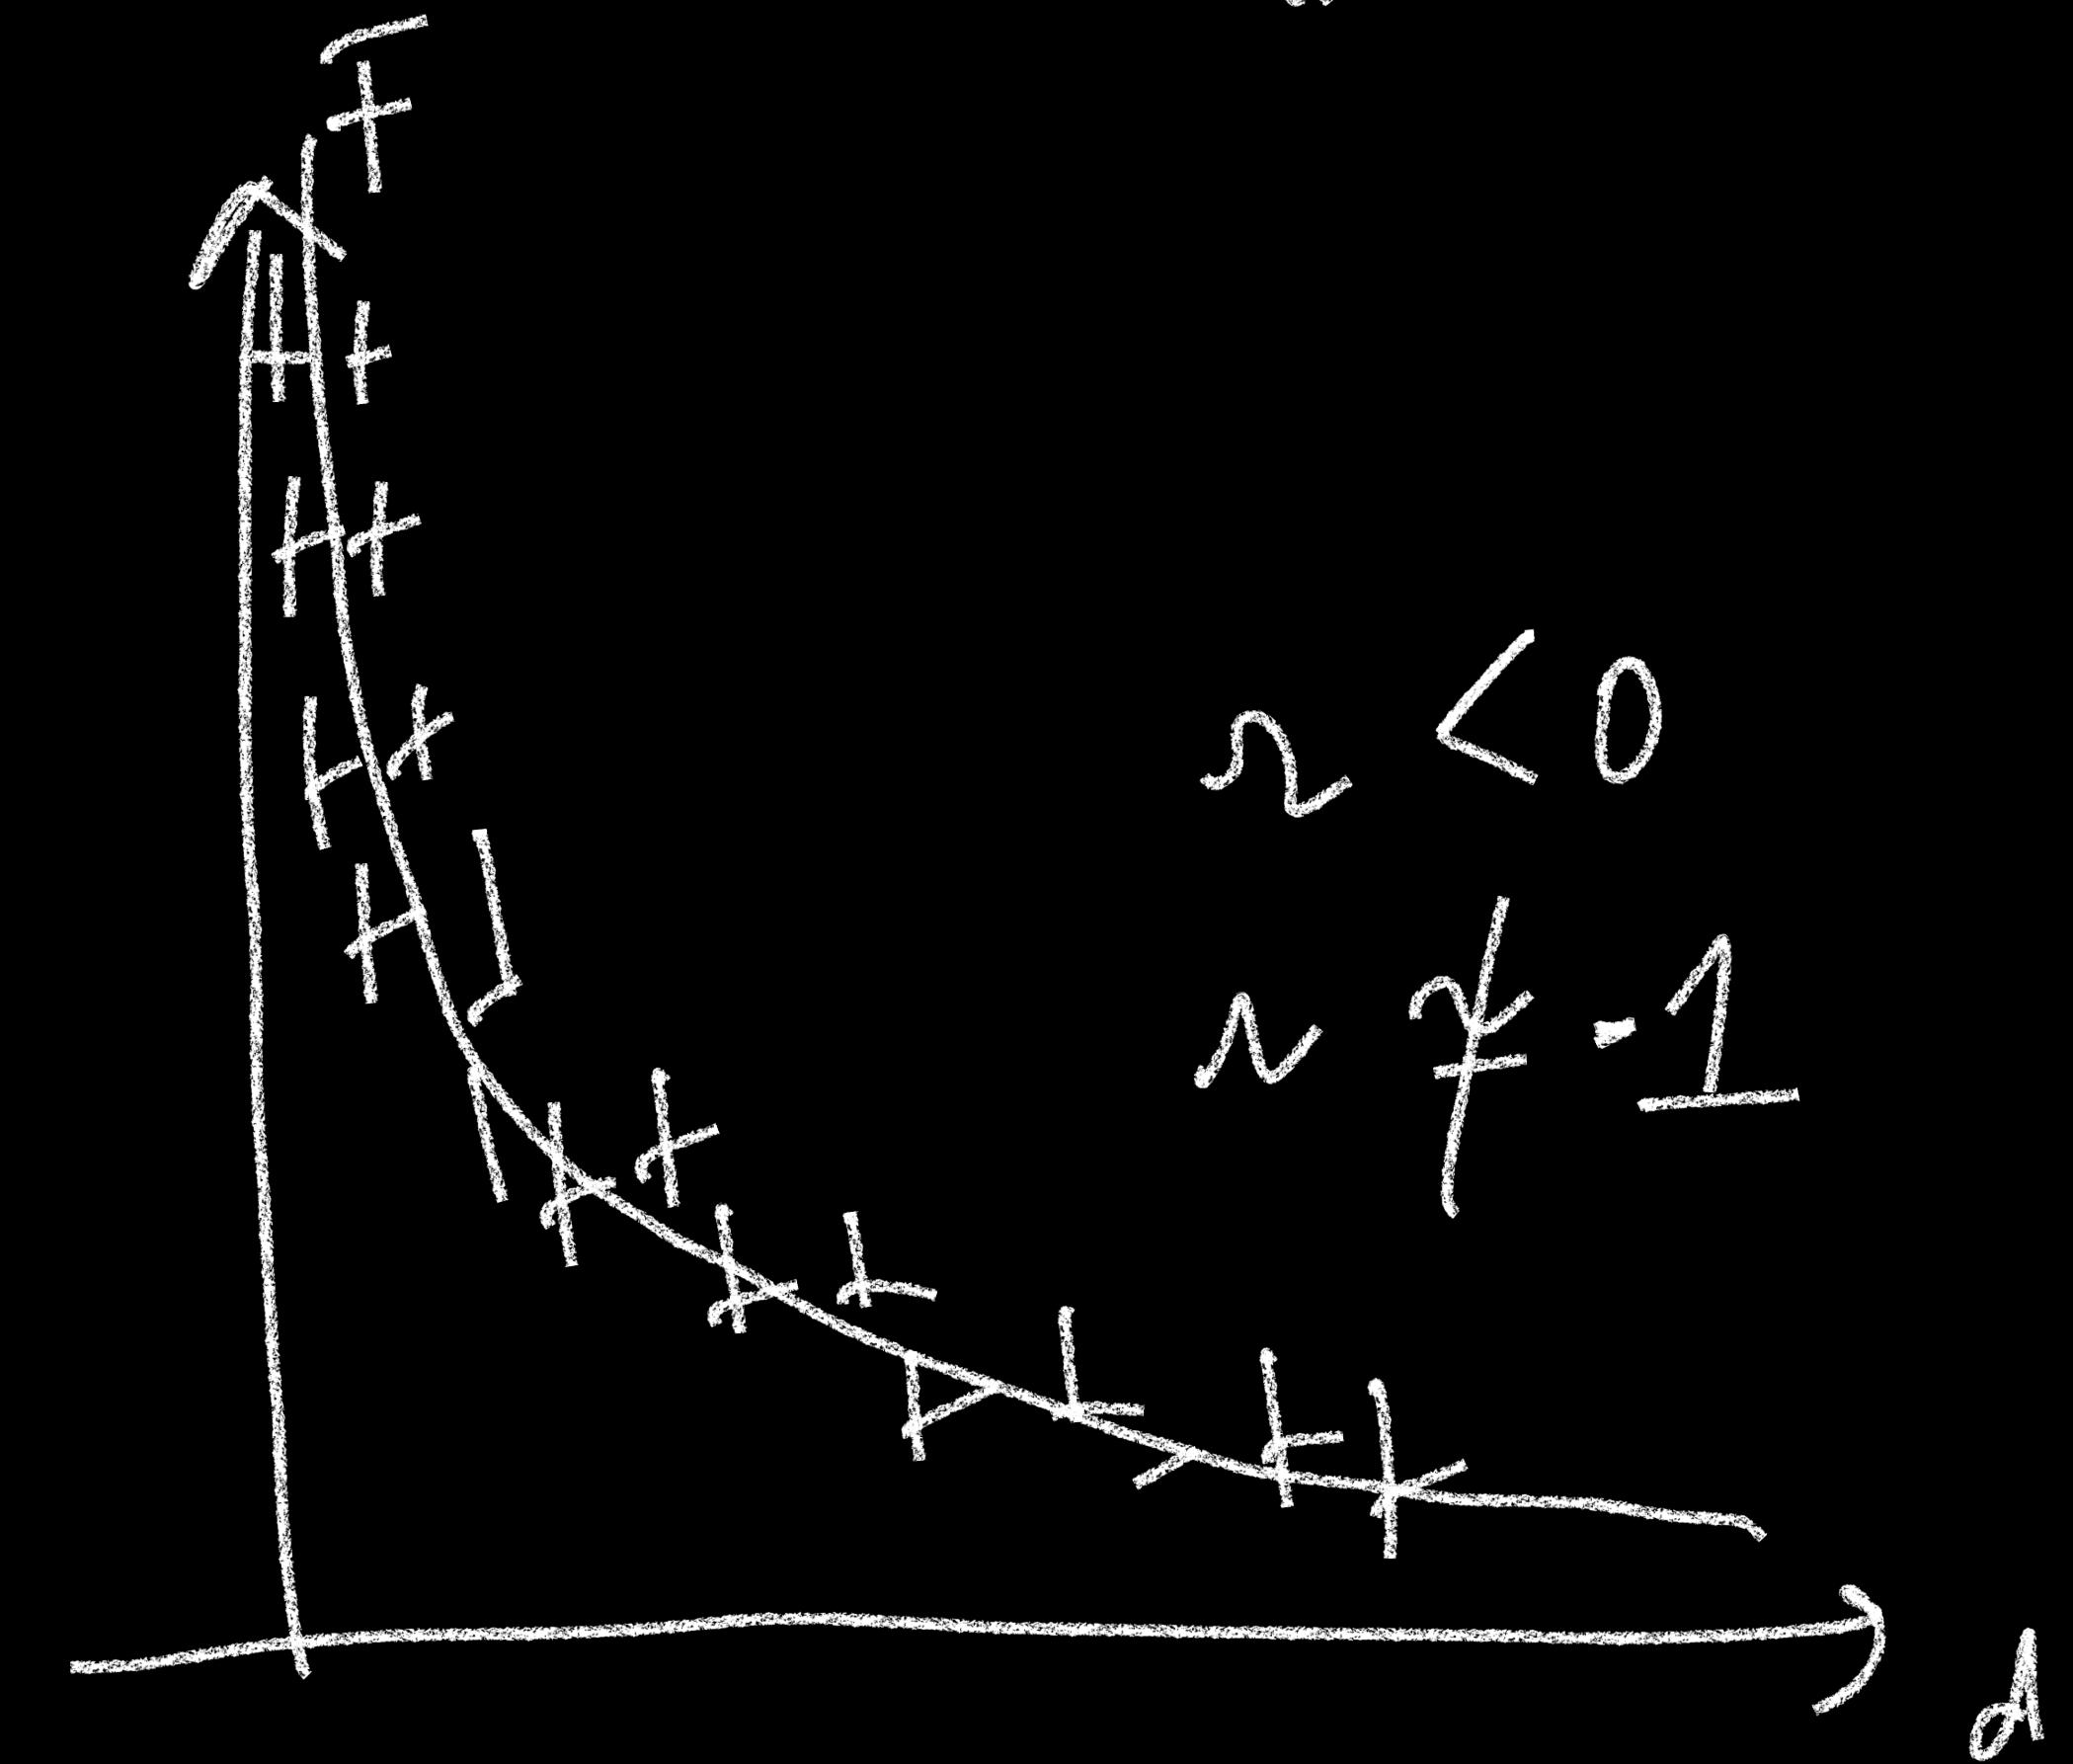
$$r^2 = 11,56\% \text{ de } Y$$

Le taux de variance^V expliquée par

X est de 11,56%.



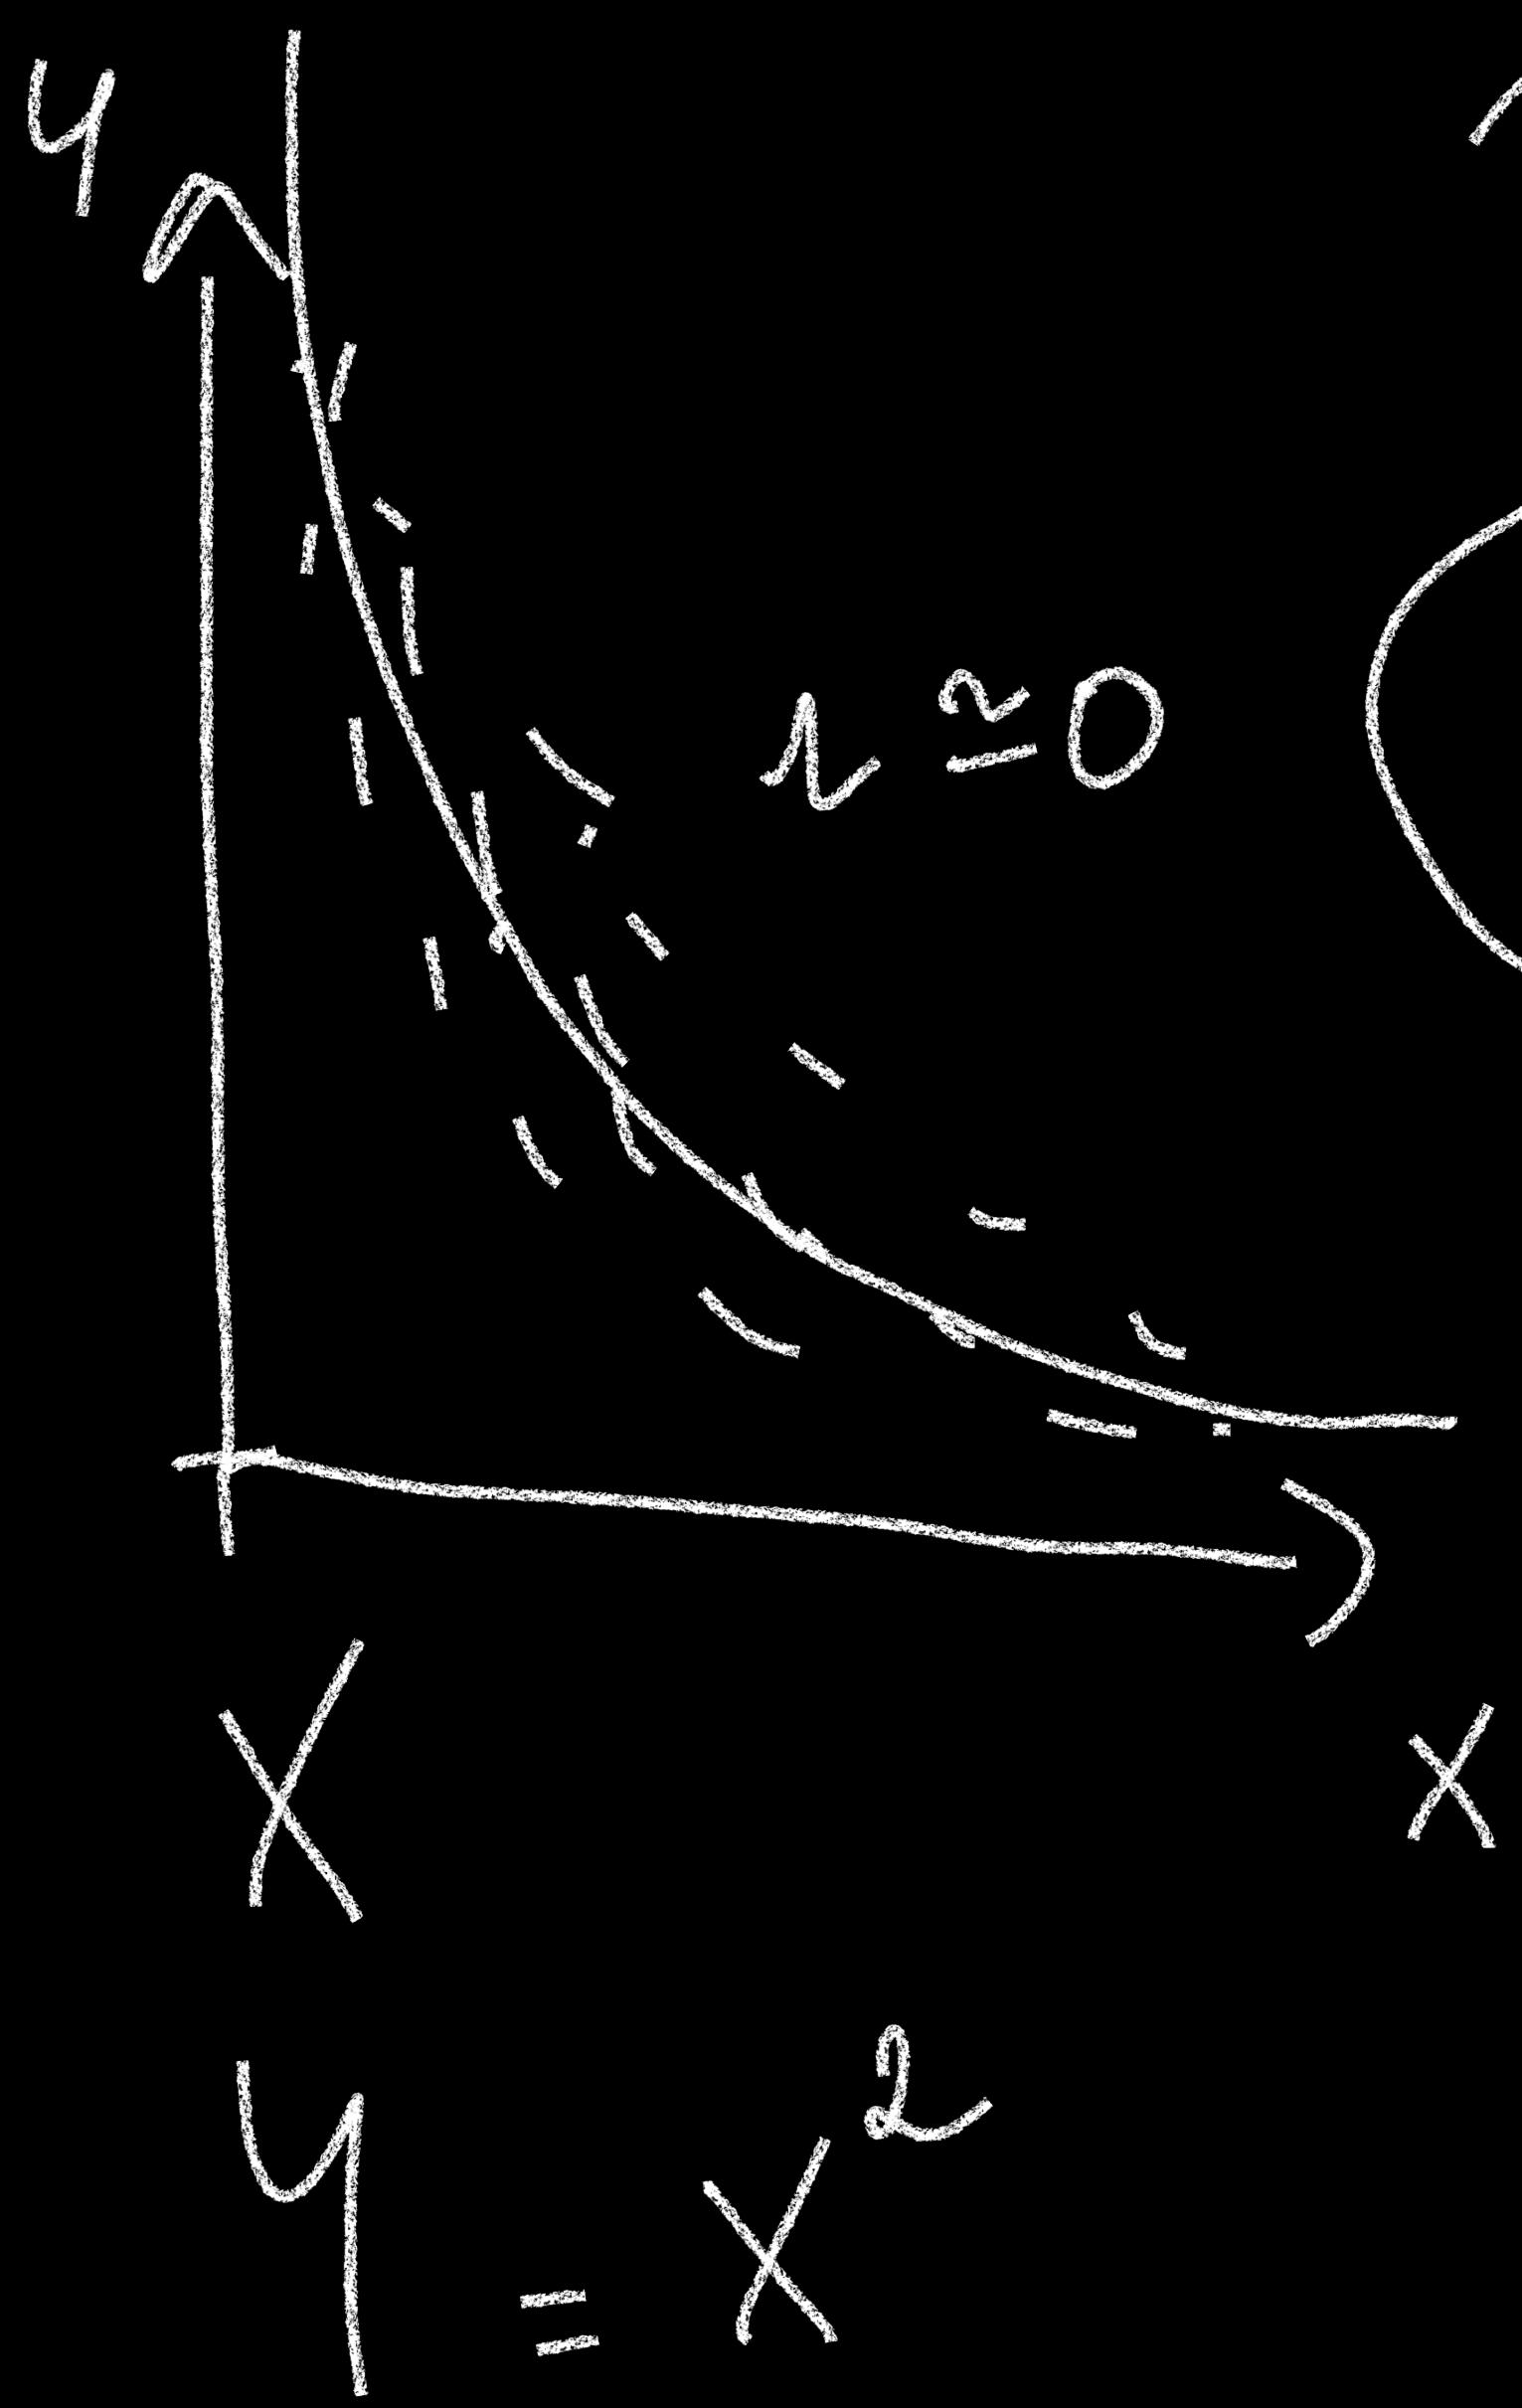
$$n \geq 1$$



$$F = \frac{G m}{d^2}$$

$$n < 0$$

$$n \neq -1$$



$$y = \frac{1}{x}$$

$$y = \frac{1}{x^2}$$

